

Atividade 2 – Arquitetura Medalhão

Projeto CineData Analytics

1. Contexto e Objetivo

Você foi designado(a) como Engenheiro(a) de Dados da **CineData Analytics**, uma empresa de inteligência de mercado do setor audiovisual. Seu trabalho consiste em estruturar os dados de um catálogo de filmes (base combinada TMDb/IMDb) na infraestrutura Data Lakehouse do Databricks.

Você implementará todo o processo de ETL para que os dados brutos — hoje entregues de forma intencionalmente suja e fragmentada, na pasta **Inputs** — fiquem prontos para gerar Data Marts analíticos, uma modelagem dimensional (Star Schema), seguindo a **Arquitetura Medalhão (Bronze, Silver e Gold)**.

Seu código e sua organização serão avaliados quanto à funcionalidade, à usabilidade, à aderência aos requisitos estabelecidos neste documento e às boas práticas de desenvolvimento em Engenharia de Dados aprendidos nas aulas.

Parte 1 — Ingestão e Preparação (Camadas Bronze e Silver)

1.1. Preparação e Upload dos Dados

Carregue os arquivos CSV disponibilizados na pasta **Inputs** como Volume no Data Lakehouse do Databricks.

1.2. Notebook — Camada Bronze

Crie um notebook responsável por:

- Criar o banco de dados (database) da camada Bronze.
- Criar as tabelas Bronze a partir de cada CSV, lendo os dados (sem qualquer alteração estrutural ou de conteúdo).
- Adicionar em cada tabela a coluna **ingestion_datetime**, contendo o timestamp exato do momento da inserção do dado na camada Bronze.
- Gravar todas as tabelas em formato Delta, utilizando o modo **Append**.

Mapeamento de Arquivos para Tabelas Bronze:

Arquivo Original	Nome da Tabela (Bronze)
movies_info_IMDB_TMDB.csv	bronze.tb_movies_info
movies_financials_IMDB_TMDB.csv	bronze.tb_movies_financials
movies_metics_IMDB_TMDB.csv	bronze.tb_movies_metrics
credits_and_tags_IMDB_TMDB.csv	bronze.tb_credits_and_tags
movies_reviews.csv	bronze.tb_movies_reviews

Ingestão de API (obrigatória):

A diretoria financeira quer acompanhar os valores de orçamento e receita dos filmes também em Reais (BRL). Extraia a cotação do dólar via API do Banco Central e salve na tabela `bronze.tb_cotacao_dolar`.

- **Endpoint:**
`https://olinda.bcb.gov.br/olinda/servico/PTAX/versao/v1/odata/CotacaoDolarPeriodo(dataInicial=@dataInicial,dataFinalCotacao=@dataFinalCotacao)?@dataInicial='{data_inicio_formatada}'&@dataFinalCotacao='{data_fim_formatada}'&$select=dataHoraCotacao,cotacaoCompra&$format=json`
- Formato esperado de data: `MM-DD-AAAA`. Use parâmetros (widgets) do notebook para as datas de início e fim.
- Sugestão: consulte os últimos 7 dias corridos a partir da data de execução, já que a API não retorna cotação em finais de semana e feriados.

1.3. Notebook — Camada Silver

Nenhuma alteração será realizada nas tabelas da camada Bronze. Todos os nomes de colunas devem estar em português e a tipagem deve estar correta.

1) `silver.tb_info_filmes` (origem: `tb_movies_info`)

Mapeamento de colunas:

Coluna Origem	Coluna Destino
<code>id</code>	<code>id_filme</code>
<code>title</code>	<code>titulo</code>
<code>original_title</code>	<code>titulo_original</code>
<code>release_date</code>	<code>data_lancamento</code>
<code>runtime</code>	<code>duracao_minutos</code>
<code>original_language</code>	<code>idioma_original</code>
<code>status</code>	<code>status_filme</code>
<code>overview</code>	<code>sinopse</code>
<code>tagline</code>	<code>frase_divulgacao</code>

- **Limpeza e Tradução do Status:** Antes de traduzir o `status_filme` (`Released` → `Lançado`; `Post Production` → `Pós-Produção`; `In Production` → `Em Produção`; `Planned` → `Planejado`; `Rumored` → `Rumores`; `Canceled` → `Cancelado`), você deve normalizar a coluna. A coluna de status deve ser normalizada (removendo ruídos, hífens sobressalentes e padronizando a caixa) antes da tradução dos termos para o português. Registros corrompidos ou não mapeáveis devem ser padronizados como "Não Informado".
- **Deduplicação:** A tabela deve conter unicidade por filme. Havendo registros duplicados na origem, mantenha exclusivamente a versão mais recente com base na data de ingestão.
- **Tratamento de Data Multi-Formato:** Converta o campo de data de lançamento testando os diferentes padrões presentes na origem de forma robusta. Apenas valores onde a conversão for estritamente impossível devem ser tratados como ausentes (NULL).
- **Coluna Derivada:** Criar a coluna `ano_lancamento`, extraída de `data_lancamento`.

2) `silver.tb_financeiro_filmes` (origem: `tb_movies_financials`)

Coluna Origem	Coluna Destino
id	id_filme
budget	orcamento_usd
revenue	receita_usd
orcamento_usd	orcamento_brl
receita_usd	receita_brl

- Tratar valores textuais que representam ausência de dado (ex.: "Unknown", "Não Informado") como NULL antes da conversão de tipo.
- Higienize as colunas de orçamento e receita para remover símbolos de moedas, pontuações de milhar e textos representativos de ausência de dados.
- Converta as métricas para o tipo numérico decimal apropriado e garanta que valores zerados ou negativos sejam tratados como ausentes.
- Calcule os valores equivalentes em Reais (BRL) aplicando a taxa de cotação obtida.
- Derive as colunas de Lucro (Dólar/Real) e Margem de Lucro Percentual, garantindo que operações aritméticas com valores ausentes não invalidem o resultado e evitando divisões por zero.

3) silver.tb_metricas_engajamento (origem: tb_movies_metrics)

Coluna Origem	Coluna Destino
id	id_filme
popularity	popularidade
vote_average	nota_media_tmdb
vote_count	qtd_votos_tmdb
averageRating	nota_media_imdb
numVotes	qtd_votos_imdb

- A coluna de popularidade apresenta inconsistências de pontuação e separadores decimais na origem. Limpe a formatação numérica da coluna antes da conversão de tipo, garantindo que os valores não sejam invalidados ou convertidos silenciosamente para nulos.
- Devido ao deslocamento de colunas (Column Shift) presente na base bruta, existem textos e atributos fora de contexto espalhados pelas colunas de notas e contagens de votos. Aplique uma conversão de tipagem segura (para valores decimais e inteiros), garantindo que textos ou caracteres incompatíveis sejam tratados como dados ausentes (NULL) sem interromper a execução do pipeline.
- Identifique e trate inconsistências de escala e limites numéricos de negócio: Notas médias (TMDB e IMDb) que estejam fora do intervalo válido de 0 a 10 (incluindo valores multiplicados por erro de escala) devem ser desconsideradas e tratadas como NULL. Contagens de votos ou índices de popularidade com valores negativos devem ser invalidados e tratados como NULL

4) silver.tb_avaliacoes_usuarios (origem: tb_movies_reviews)

Coluna Origem	Coluna Destino
id	id_filme
nome	nome_usuario
nota	nota_usuario
comentario	comentario_usuario

- Remova registros integralmente duplicados (onde a combinação de filme, usuário, nota e comentário seja idêntica), garantindo a unicidade das avaliações.
- Garanta que a nota atribuída pelo usuário respeite a regra de negócio da escala permitida (0 a 10). Qualquer valor fora dessa faixa deve ser descartado e convertido para NULL.
- Identifique comentários não preenchidos ou compostos apenas por espaços em branco e preencha-os de forma explícita com o texto padronizado "Sem comentário".

5) silver.tb_generos (origem: tb_credits_and_tags, coluna genres)

- Explodir (split + explode) a coluna genres, tratando a inconsistência de separadores (vírgula vs. ponto e vírgula) antes do split.
- A origem armazena múltiplos valores delimitados na mesma coluna. Desmembre estes elementos para que cada registro represente um único gênero ou participante/empresa por filme.
- Devido a falhas na estrutura de origem (Column Shift e separadores extras), remova resíduos em branco, textos descritivos e valores numéricos deslocados que não pertençam ao domínio de gêneros ou nomes de entidades.

6) silver.tb_pessoas_empresas (origem: tb_credits_and_tags, colunas cast, directors, writers, production_companies)

Dimensão unificada que consolida quatro tipos de entidade em uma única tabela:

Coluna Origem	tipo_entidade Resultante
cast	'Ator'
directors	'Diretor'
writers	'Roteirista'
production_companies	'Produtora'

- Dimensão unificada que consolida quatro tipos de entidade em uma única tabela (Manter o mapeamento de tipos de entidade: cast -> 'Ator' etc.).
- Padronize a formatação de capitalização de texto, consolide as entidades em um modelo unificado categorizado pelo tipo de atuação (Ator, Diretor, Roteirista, Produtora) e elimine registros duplicados.

7) silver.tb_cotacao_dolar (origem: tb_cotacao_dolar)

- Como a API do Banco Central não possui cotações em finais de semana e feriados, estruture o histórico de forma a garantir uma série temporal contínua.
- Aplique uma técnica de preenchimento (Forward Fill) de modo que dias sem cotação recebam o valor do último dia útil disponível.

Parte 2 — Consagração do Negócio (Camada Gold)

Nesta etapa você construirá os Data Marts consolidados, a modelagem dimensional (Star Schema) para consumo do time de BI, e a tabela de contexto para o time de IA. Utilize exibições de DataFrames em tela (`display()`) para responder às perguntas de negócio solicitadas. Nenhuma biblioteca de visualização de gráficos é necessária.

Entrega 1 — Modelagem Dimensional (Star Schema)

Construa as seguintes tabelas, utilizando chaves substitutas (Surrogate Keys) geradas via `monotonically_increasing_id()`, `row_number()` ou função de hash (`sha2`):

- **gold.fact_movies_performance**
 - **Grão:** Um registro único por filme.
 - **Objetivo:** Centralizar todas as métricas financeiras e de engajamento do filme.
 - **Chave Estrangeira (FK):** `sk_movie_id` BIGINT (Apontando para a `dim_movies`).
 - **Métricas Financeiras (DECIMAL):** `orcamento_usd` DECIMAL(18,2), `receita_usd` DECIMAL(18,2), `lucro_usd` DECIMAL(18,2), `orcamento_brl` DECIMAL(18,2), `receita_brl` DECIMAL(18,2), `lucro_brl` DECIMAL(18,2).
 - **Métricas de Engajamento (DOUBLE/INT):** `popularidade` DOUBLE, `nota_media_tmdb` DOUBLE, `qtd_votos_tmdb` INT, `nota_media_imdb` DOUBLE, `qtd_votos_imdb` INT.
 - A tabela fato deve consolidar métricas de filmes lançados sem duplicar grão através dos joins.
- **gold.dim_movies**
 - **Objetivo:** Armazenar os metadados principais e descritivos de cada filme.
 - **Colunas:** `sk_movie_id` BIGINT (PK), `id_filme` STRING (Chave natural de origem), `titulo` STRING, `data_lancamento` DATE, `ano_lancamento` INT, `duracao_minutos` INT, `idioma_original` STRING, `status_filme` STRING, `sinopse` STRING.
- **gold.dim_genres**
 - **Objetivo:** Catálogo único e deduplicado de todos os gêneros cinematográficos.
 - **Colunas:** `sk_genre_id` BIGINT (PK), `nome_genero` STRING.
- **gold.dim_people**
 - **Objetivo:** Consolidar todas as pessoas físicas envolvidas na obra.
 - **Colunas:** `sk_person_id` BIGINT (PK), `nome_pessoa` STRING, `tipo_pessoa` STRING (Apenas valores como: 'Ator', 'Diretor', 'Roteirista').
- **gold.dim_companies**
 - **Objetivo:** Catálogo único de produtoras/estúdios.
 - **Colunas:** `sk_company_id` BIGINT (PK), `nome_produtores` STRING.
- **gold.dim_reviews**

- **Objetivo:** Consolidar as avaliações individuais geradas pelos usuários, transformando-as em uma métrica resumida por filme.
- **Colunas:** sk_review_id BIGINT (PK), sk_movie_id BIGINT (FK para o filme correspondente), qtd_avaliacoes_usuarios INT (Contagem), nota_media_usuarios DOUBLE (Média arredondada em 2 casas decimais).

Como um filme pode ter vários gêneros, vários atores e várias produtoras (e vice-versa), o uso de tabelas-ponte (bridge tables*) é estritamente necessário para conectar a tabela dim_movies às dimensões periféricas sem duplicar o registro da tabela Fato.

- gold.bridge_movie_genre
 - **Colunas:** sk_movie_id BIGINT (FK), sk_genre_id BIGINT (FK).
- gold.bridge_movie_person
 - **Colunas:** sk_movie_id BIGINT (FK), sk_person_id BIGINT (FK).
- gold.bridge_movie_company
 - **Colunas:** sk_movie_id BIGINT (FK), sk_company_id BIGINT (FK).

*se você quiser entender mais sobre bridge tables, visite [Medium](#), [Data Warehouse Info](#), [Kimball group](#)

4. Desafio de Analytics

Para validar sua modelagem Gold, resolva as consultas abaixo, as quais abordam perguntas que poderiam ser recorrentes em pautas do dia a dia de um Analista de Dados.

Perguntas de Negócio:

- 1. Qual é a receita total (em R\$) somada de todos os filmes da base?
- 2. Quais são os 5 filmes com maior popularidade? Mostre título e valor de popularidade.
- 3. Quantos filmes cada gênero possui? Liste do maior para o menor volume.
- 4. Para os 10 filmes de maior receita, mostre título, receita (em US\$ e R\$) e a posição de cada um no ranking (RANK()).
- 5. Qual ator teve a maior quantidade de participações nos filmes lançados nos últimos 2 anos*?
- 6. Qual a produtora de filmes teve o maior Lucro nos últimos 5 anos*?

*Para o recorte dos últimos 2 e 5 anos, considere como data limite superior a data de lançamento realizada mais recente na base (ignorando registros com datas futuras ou não lançadas).

5. Formato de Entrega

- Entregar os notebooks com os códigos em formato .ipynb.
- Incluir comentários explicativos no código justificando as regras de negócio aplicadas.
- Publicar os arquivos em um repositório GitHub público.

Prazo de Entrega

A atividade deve ser entregue até **quarta-feira, dia 07/10/2026, às 19:00**. Seu código e organização serão avaliados quanto à funcionalidade, usabilidade, aderência aos requisitos estabelecidos e boas práticas de desenvolvimento.